

구현 현황과 막힌 이유

CTFM - CIM Simulations · 개정 2026 - 09 - 20
무엇을 구현했고, 무엇이 남았고, 남은 것이 왜 막혀 있는지 근거와 함께 정리했습니다.
검증 기준: Windows · Linux 양쪽 159 passed / 3 skipped · 브랜치 codex/p0 - api - contracts (HEAD 8926fd0) · 커밋/push 없음

1 · 한눈에

항목		내용	상태 · 사유
완료	NeuroSim 엔진 입력 조립기	NetWork csv · weight/activation trace 생성	실제 엔진이 받아들임 · rc=0
완료	Ron/Roff 전달	프로필 실측 상태에서 산출	20 kΩ / 100 kΩ 확인
완료	preset export	effective preset JSON + SHA256	거부된 실행에서도 기록
완료	trace 연결	test 앞 256개를 엔진 활성화 입력으로	레이어별 입력 포착
완료	정규화 기록	NeuroSim [- 1, 1] 범위 대응	레이어별 divisor 저장
완료	절대 경로 누출 수정	응답에 서버 경로가 새던 문제	filename + sha256만 노출
완료	웹 PPA 표시	상태 · 사유 · 모델 차이 렌더링	명세 04 요구사항 충족
완료	A1 회귀 하네스	파일 오면 즉시 실행	사유 명시 skip
완료	preset 템플릿	소자팀이 값만 채우는 형태	필수 필드 전부 포함
막힘	차동 2 plane 비용 모델	두 번째 plane의 면적 · 에너지 · 지연	결정 A5 대기
막힘	실제 PPA 수치 산출	면적 · 에너지 · 지연	preset 부재 + 엔진 형상 제약
막힘	ADC bits → levelOutput 반영	사용자 선택을 엔진에 전달	재빌드 설계 필요 (C1)
막힘	A1 원본 실측 회귀	명세 P1 마지막 인수 기준	원본 파일 미제공

2 · 이번에 구현한 것

이전까지 NeuroSim 어댑터에는 부품만 있고 조립기가 없었습니다. 인코더 · NetWork csv 생성 · Ron/Roff 산출 · 실행 · 파싱은 있었지만, 실제 실험의 nominal 매핑에서 이것들을 조립하는 코드가 없어 프로덕션 경로에서 한 번도 호출되지 않았습니다.

`build_engine_inputs()` 를 추가해 연결했습니다. nominal 매핑 가중치와 trace 앞 256개에서 포착한 레이어별 입력으로 엔진 입력 일체를 만듭니다. 레이어 입력은 별도 forward를 새로 구현하지 않고 기존 Network 의 공유 지점 한 곳에서 포착하므로, 정확도 경로와 어긋날 수 없습니다.

NeuroSim은 weight를 `algoWeightMin/Max = -1/+1` 범위로 정규화합니다(Param.cpp 120 - 121행). 그래서 nominal `w_hat` 을 그 범위로 나누고 레이어별 divisor를 결과에 기록합니다. 수치가 배울 없이 나오지 않도록 하기 위한 것이며, 이 선형 재배치 자체가 `model_mismatches` 의 한 항목입니다.

실제 엔진 검증

`scripts/linux/verify_neurosim_adapter.py` 결과:

검사	결과
<code>writer_parity</code> — 상류 writer와 바이트 동일	OK
<code>engine_roundtrip</code> — 실제 stdout 파싱	OK
<code>preset_gate_closed</code> — gate 폐쇄 확인	OK
<code>assembled_inputs_accepted</code> — 조립기 출력을 엔진에 투입	OK

조립기 출력을 빌드된 바이너리에 그대로 넣어 `returncode 0`, `chip_area` $7.41\text{e-}07\text{ m}^2$ 파싱, `Ron` 20 k Ω / `Roff` 100 k Ω 전달을 확인했습니다. 검증 형상은 784×128 단일 레이어입니다 — `mnist_mlp_v1` 전체 형상이 아닌 이유는 3 - B에 있습니다.

3 · 앞으로 구현해야 할 것과 막힌 이유

A
차동 2 plane 비용

막는 것 — 물리 판단이 없음 (결정 A5)

정확도 모델은 weight 하나를 plane당 analog cell 1개씩 두 plane에 저장하고 $G^+ - G^-$ 로 읽습니다. NeuroSim에는 이런 두-plane 차동 배열이 없어서, 두 번째 plane의 면적 · 에너지 · 지연을 반영하려면 명시적 근사를 세워야 합니다.

근사를 코드로 정해버리면 그 순간 검증되지 않은 CTFM PPA가 생깁니다. 엔지니어링 판단이 아니라 물리 판단이므로 임의로 정하지 않고, 모든 결과의 `reasons[]` 에 사유를 남기도록 했습니다.

필요한 결정: 2배 단순 배수로 볼지, 공유 주변회로를 감안할지, unsupported로 둘지.

B
실제 PPA 수치

막는 것 — 두 가지가 동시에

	막는 것	내용
B - 1	검증된 CTFM preset 부재	NeuroSim에 CTFM 셀 분기가 없고, 등가 셀 · 면적 · 접근 구조 · 공정 노드가 정해지지 않았습니다. upstream 기본값은 SRAM · 22 nm이며 CTFM 값이 아닙니다.
B - 2	엔진이 모델 형상에서 죽음	출력층이 10이라 <code>CopyPEArray</code> 내부 SIGSEGV. 출력 96 미만은 전부 crash, 96 이상은 정상. 폭이 균일한 다층 FC는 정상.

두 제약은 독립적입니다. B - 1만 풀리면 여전히 `mnist_mlp_v1`은 돌지 않고, B - 2만 풀리면 여전히 그 수치를 CTFM PPA라고 부를 수 없습니다.

C
ADC bits 반영

막는 것 — 런타임 설정이 없음 (결정 C1)

사용자가 고른 ADC bit를 엔진에 넘기려면 `levelOutput = 2^bits` 를 바꿔야 하는데, 이 값은 `Param.cpp` 의 컴파일 타임 상수입니다. CLI로 넘길 수 있는 것은 `network.csv`, `synapse_bit`, `input_bit`, `subArray`, `parallelRead` 와 `trace` 파일뿐입니다.

즉 preset 하나 = 바이너리 하나입니다. 격리 빌드 + 캐시 구조를 먼저 정하지 않으면 동시 실행이 서로의 `Param.cpp` 를 덮어쓰게 됩니다.

승인만 주시면 이 인프라는 preset 물리값과 무관하게 지금 시작할 수 있습니다.

D
A1 원본 회귀

막는 것 — 데이터 미제공

명세 P1의 마지막 인수 기준입니다. 테스트는 이미 작성해 뒀고 기대값도 명세에서 가져왔습니다. CTFM_A1_FILE 로 파일을 가리키면 즉시 실행되며, 지금은 사유를 명시한 skip 상태입니다.

컬럼 매핑도 추측하지 않고 CTFM_A1_COLUMNS 로 명시하게 했습니다. 명세가 매핑 추론을 금지하기 때문입니다.

4 · 막힌 것을 어떻게 다루고 있는가

막혀 있다고 값을 비워두기만 한 것은 아닙니다. 다음 원칙을 코드와 테스트로 강제합니다.

원칙	구현	이를 강제하는 테스트
미실행 값은 0이 아니라 null	area_m2 · energy_j_per_inference · latency_s_per_inference · raw_output 전부 None	test_ppa_result_never_fabricates_numbers
거부 사유를 전부 나열	reasons[] 에 preset · 엔진 빌드 · 형상 · 차동 plane 사유가 각각	test_second_plane_cost_is_named_as_unresolved
upstream 기본값을 CTFM으로 위장하지 않음	SRAM · 22 nm 값이 와도 validated_for_ctfm 없으면 거부	test_stock_upstream_values_are_not_a_ctfm_preset
write pulse를 read latency로 전용 금지	read_pulse_width_s == 1e-3 이면 거부	test_write_pulse_cannot_be_reused_as_read_latency
모델 차이를 항상 기록	model_mismatches 5종을 모든 결과에 첨부	test_model_mismatches_are_always_recorded
서버 경로를 응답에 넣지 않음	filename + sha256만 반환, argv는 basename만	test_preset_is_written_with_a_hash_even_when_refused
엔진 crash가 worker를 죽이지 않음	별도 subprocess · 프로세스 그룹 종료 · SIGSEGV는 failed(음수 rc)	실측 형상 스왑
설치 상태와 preset 상태를 분리	capability reason이 '엔진 빌드됨(commit ...)'과 'preset 없음'을 따로 표시	Windows / Linux 양쪽 출력 대조

결과에 항상 기록되는 구조적 모델 차이

id	내용
nonuniform_states	CTFM은 비균일 실측 전도도, NeuroSim은 min~max 균일 레벨
cells_per_weight	정확도 모델은 plane당 1 cell, NeuroSim은 ceil(synapse_bit/cell_bit) 컬럼
differential_planes	NeuroSim에 두-plane 차동 표현 없음
read_voltage	측정 VDS 0.1 V, NeuroSim은 technode에서 readVoltage 결정 (22 nm → 0.55 V)
adc_position	차동 차감 후 양자화 vs 물리 컬럼 그룹별 양자화

5 · 지금 상태

정확도 경로(PyTorch · AIHWKit)는 실제 MNIST로 검증을 마쳤고, NeuroSim은 빌드 · 실행 · 입력 조립 · 출력 파싱까지 실제 바이너리로 확인했습니다. 남은 것은 물리 결정 3건(A5 · preset · C1)과 엔진 형상 제약 1건, 원본 데이터 1건입니다.

검증되지 않은 CTFM PPA 수치는 하나도 생성하지 않았습니다. `engines.ppa = off`, `preset_id = null` guard는 그대로이며, C2C도 데이터 계약 확정 전까지 비활성입니다.

결정 대기 목록은 같은 폴더의 정해야할것.pdf 에 있습니다.